

دانشگاه صنعتی امیرکبیر

(پلی‌تکنیک تهران)

دانشکده مهندسی کامپیوتر

گزارش سمینار کارشناسی ارشد

مهندسی کامپیوتر-معماری سیستم‌های کامپیوتری

شتا بدھی سخت افزاری پیش‌بینی عمر باقی‌مانده مفید
دستگاه‌های دوار با استفاده از شبکه عصبی ترانسفرمر بر بستر
FPGA

نگارش

رضا آدینه پور

استاد راهنما

جناب آقای دکتر مرتضی صاحب‌الزمانی

۱۴۰۳ مرداد



اول

سپاس

از استاد بزرگوارم، جناب آقای دکتر مرتضی صاحب‌الزمانی، که به بنده اعتماد کردند و با کمک‌ها و راهنمایی‌های بی‌دریغ‌شان، مرا در به سرانجام رساندن این پایان‌نامه یاری دادند، سپاسگزاری و قدردانی می‌کنم. حمایت‌های مستمر و بی‌وقفه ایشان، نه تنها انگیزه و توان مضاعفی به من بخشید، بلکه مسیر پژوهشی این پایان‌نامه را با روشنایی دانش و تجربه‌شان هموار ساخت. بدون همراهی، مشورت‌ها و تشویق‌های استاد محترم، تحقق این هدف امکان‌پذیر نمی‌بود. از صمیم قلب برای ایشان آرزوی سلامتی، موفقیت و برکت دارم.

چنان محنون شوم گویی که شهرآشوب دورانم
نه پندی و نه اندرزی به گوشم پنبه چسباندم
بماند یادگار این شعر
که من از دار این دنیا فقط این شعر می‌دانم.

چکیده

در محیط‌ها و کارخانه‌های صنعتی، همواره یکی از مهم‌ترین دغدغه‌ها، نگهداری و تعمیر ابزارآلات و دستگاه‌های صنعتی است. دستگاه‌هایی که هرکدام وظیفه‌ای مهم را در خط تولید هر شرکتی بر عهده دارند و کوچک‌ترین آسیب و خرابی می‌تواند خط تولید شرکت را مختل کند. بنابراین، نیاز است که همواره بتوانیم وضعیت فعلی سلامت دستگاه‌ها را مورد پایش قرار دهیم و بتوانیم زمان خرابی دستگاه و عمر مفید باقی‌مانده آن را پیش‌بینی نماییم.

پیش‌بینی عمر مفید باقی‌مانده مفید (Remaining Useful Life) یا به اختصار RUL وظیفه‌ای بسیار مهم در زمینه پیش‌بینی و مدیریت سلامت (PHM) ابزار و تجهیزات صنعتی است. پیش‌بینی دقیق RUL امری حیاتی و مهم است چرا که امکان تعمیر و نگهداری به موقع را فراهم می‌کند، مدت زمان خرابی دستگاه را کاهش می‌دهد و می‌توان بر اساس عمر مفید باقی‌مانده دستگاه، آن را تحت بار قرار داده و کارایی عملیاتی را بهبود بخشد.

کلیدواژه‌ها: عمر باقی‌مانده مفید، RUL، ترانسفرمر، FPGA

فهرست مطالب

۱	۱	مقدمه
۱	۱-۱	تعريف مسئله
۲	۲-۱	اهمیت موضوع
۲	۳-۱	اهداف پژوهش
۲	۴-۱	ساختار پایان نامه
۳	۲	مفاهیم اولیه
۳	۱-۲	عمر باقی مانده مفید
۴	۱-۱-۲	اولین زمان خرابی
۴	۲-۱-۲	عمر پایانی دستگاه
۵	۲-۲	داده ها
۶	۱-۲-۲	مجموعه داده XJTU-SY
۸	۲-۲-۲	مجموعه داده PRONOSTIA
۱۲	۳-۲-۲	مجموعه داده C-MAPSS
۱۳	۳-۲	شبکه عصبی ترانسفرمر
۱۴	۱-۳-۲	ساختار کلی شبکه
۱۴	۲-۳-۲	ورودی تعبیه شده
۱۵	۳-۳-۲	تعبیه موقعیتی

۱۷	توجه چند سر	۴-۳-۲
۲۰	لایه رو به جلو	۵-۳-۲
۲۱	لایه خطی رمزگشای	۶-۳-۲
۲۱	لایه خطی رمزگذار	۷-۳-۲
۲۲	کارهای پیشین	۳
۲۵	چالش‌ها و نوآوری‌ها	۴
۲۶	نتیجه‌گیری	۵
۲۷	مراجع	
۲۹	واژه‌نامه	
۳۱	آ مطالب تکمیلی	

فهرست جداول

۱-۲	پارامترهای بلبرینگ‌های آزمایش شده	۷
۲-۲	اطلاعات مجموعه‌داده XJTU-SY	۸
۳-۲	تقسیم بندی داده‌های جمع‌آوری شده در مجموعه داده PRONOSTIA	۱۱
۴-۲	مشخصات داده‌های ضبط شده در فایل‌های csv	۱۱
۵-۲	اطلاعات زیرمجموعه‌ها در مجموعه‌داده C-MAPSS	۱۳

فهرست تصاویر

۱-۲	تابع تقریب زننده عمر باقی مانده یک دستگاه	۳
۲-۲	سیگنال ارتعاش بلبرینگ از ابتدای فعالیت تا تخریب کامل [۱]	۴
۳-۲	سیگنال RUL شکل [۱]، ۲-۲	۵
۴-۲	بستر تهیه مجموعه داده XJTU-SY [۲]	۶
۵-۲	تنظیمات نمونه برداری برای سیگنال های ارتعاشی	۷
۶-۲	سیگنال های ارتعاش افقی و عمودی و RUL بلبرینگ ۲-۱	۸
۷-۲	سیگنال های ارتعاش افقی و عمودی و RUL بلبرینگ ۲-۲	۹
۸-۲	بستر تهیه مجموعه داده PRONOSTIA [۳]	۹
۹-۲	تنظیمات نمونه برداری سیگنال ها در این آزمایش	۱۰
۱۰-۲	سیگنال خام تهیه شده در این آزمایش و بلبرینگ تخریب شده، [۳]	۱۰
۱۱-۲	چند سیگنال تصادفی خام جمع آوری شده توسط حسگرهای در موتور از مجموعه داده آموزشی	
۱۲	FD002 [۴]	
۱۲-۲	ساختار کلی شبکه ترانسفرمر	۱۴
۱۳-۲	تبدیل کلمات به بردار	۱۵
۱۴-۲	خروجی گرافیکی بلوک تعبیه موقعیتی به ازای $i = ۹۶$ و $d = ۴۸$	۱۶
۱۵-۲	جمع بردارهای ورودی با بردارهای موقعیتی تعبیه شده	۱۶
۱۶-۲	عملیات ورودی تعبیه شده و تعبیه موقعیتی	۱۷
۱۷-۲	لایه توجه به خود	۱۸

۱۹	۱۸-۲ لایه خطی
۱۹	۱۹-۲ فرایند اعمال فیلتر توجه به تصویر
۱۹	۲۰-۲ فیلترهای توجه مختلف در تصویر
۲۰	۲۱-۲ لایه توجه چند سر
۲۱	۲۲-۲ لایه روبه جلو
۲۳	۱-۲ مدل ارائه شده مبتنی بر بردارهای پشتیبان در [۵]
۲۴	۲-۲ نتایج ارائه شده [۵]
۲۴	۳-۲ نتایج ارائه شده [۶]

فصل ۱

مقدمه

پیش‌بینی عمر مفید باقی‌مانده^۱ (یا به اختصار RUL) یکی از مباحث کلیدی در حوزه مدیریت سلامت و پیش‌بینی^۲ (PHM) ابزارها و تجهیزات صنعتی است. RUL به مدت زمانی اشاره دارد که یک دستگاه یا ابزار قبل از رسیدن به نقطه خرابی و از کار افتادن نهایی، می‌تواند به طور مؤثر کار کند. این حوزه پژوهشی با استفاده از تکنیک‌های مختلف و پیشرفته در تلاش است تا به صنایع کمک کند تا بهره‌وری و کارایی خود را افزایش دهند و هزینه‌های ناشی از تعمیر و نگهداری غیرضروری را کاهش دهند.

۱-۱ تعریف مسئله

در صنایع مختلف، از جمله خودروسازی، هواپیما، نفت و گاز و تولیدات صنعتی، تجهیزات و ماشین‌آلات به طور مداوم تحت شرایط کاری سخت و پیچیده قرار دارند. هرگونه خرابی ناگهانی این تجهیزات می‌تواند به وقایع غیرمنتظره در تولید منجر شود که علاوه بر خسارات مالی، ممکن است اثرات زیان‌باری بر کیفیت محصول نهایی و رضایت مشتریان داشته باشد. بنابراین، نیاز است که وضعیت فعلی سلامت دستگاه‌ها به طور مستمر پایش شود و زمان خرابی دستگاه و عمر مفید باقی‌مانده آن با دقت بالایی پیش‌بینی شود. این پیش‌بینی نیازمند استفاده از تحلیل داده‌های حسگرها، مدل‌سازی ریاضی و الگوریتم‌های یادگیری ماشین^۳ و عمیق^۴ است.

¹Remaining Useful Life

²Prognostics and Health Management

³Machine Learning

⁴Deep Learning

۲-۱ اهمیت موضوع

اهمیت پیش‌بینی دقیق RUL در صنعت به دلیل تاثیر مستقیم آن بر بهره‌وری، کارایی و کاهش هزینه‌های تعمیر و نگهداری غیرضروری، به خوبی شناخته شده است. تکنیک‌های پیشرفته در حوزه هوش مصنوعی^۵ و تحلیل داده‌های بزرگ^۶ این امکان را فراهم کرده‌اند که داده‌های جمع‌آوری شده از تجهیزات به صورت بلادرنگ^۷ تحلیل شوند و مدل‌های پیش‌بینی RUL با دقت بالاتری ارائه شوند. این پیشرفتهای، به شرکت‌ها این امکان را می‌دهد که فرآیندهای نگهداری و تعمیرات خود را بهینه‌سازی کنند و تصمیم‌گیری‌های بهتری در زمینه مدیریت دارایی‌های خود انجام دهند.

۳-۱ اهداف پژوهش

این پژوهش بر توسعه یک راه حل شتابدهی سخت‌افزاری بر بستر FPGA پیش‌بینی RUL با استفاده از شبکه عصبی مصنوعی که وظیفه آن آموزش و یادگیری توالی و درنهایت پیش‌بینی آن است تمرکز دارد. با استفاده از قابلیت پردازش موازی FPGA و همچنین توان مصرفی بسیار پایین آن، هدف ما افزایش کارایی و مقیاس‌پذیری سیستم‌های پیش‌بینی RUL به ویژه برای دستگاه‌های دوار است.

۴-۱ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل به شرح زیر ارائه می‌شود. مفاهیم اولیه‌ی و نحوه‌ی کار شبکه عصبی ترانسفرمر در فصل «۲»^۸ اشاره شده است. فصل «۳»^۹ به مطالعه و بررسی کارهای پیشین مرتبط با پیش‌بینی عمر باقی‌مانده می‌پردازد. در فصل «۴»^{۱۰}، چالش‌های موجود در این پژوهش و راه حل‌های ما برای رفع این چالش‌ها ارائه شده است. فصل «۵»^{۱۱} به جمع‌بندی کارهای انجام شده در این پژوهش و ارائه‌ی پیشنهادهایی برای انجام کارهای آتی خواهد پرداخت.

⁵ Artificial Intelligence

⁶ Big Data Analytics

⁷ Real Time

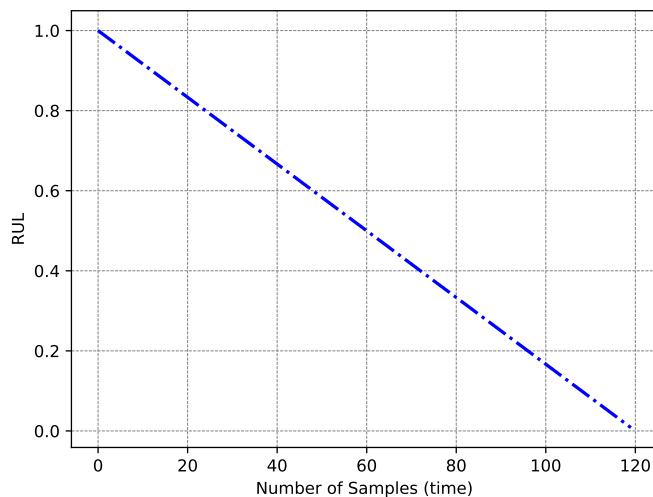
فصل ۲

مفاهیم اولیه

۱-۲ عمر باقی‌مانده مفید

مانند انسان‌ها، همه دستگاه‌ها و قطعات نیز عمری دارند و برای پایش سلامت دستگاه نیاز است که بتوانیم از عمر باقی‌مانده قطعه مطلع باشیم.

عمر یک قطعه را می‌توان به‌وسیله یک تابع خطی که آن را تابع RUL می‌نامیم «شکل ۳-۲» تقریب بزنیم.



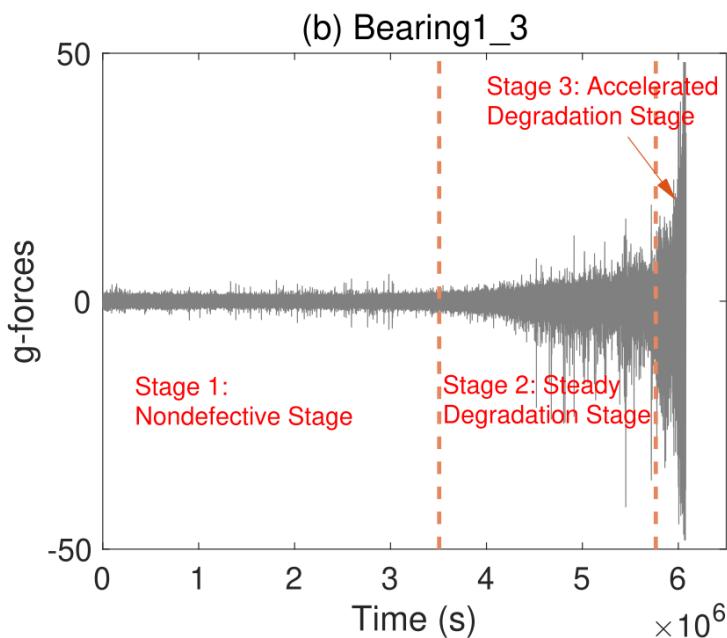
شکل ۱-۲: تابع تقریب زننده عمر باقی‌مانده یک دستگاه

محور عمودی در شکل «۳-۲» نشان‌دهنده میزان سلامت دستگاه و محور افقی نشان‌دهنده زمان است که معمولاً بر حسب دقیقه بیان می‌شود.

همه دستگاه‌ها زمانی که در آستانه بروز خطا و خرابی قرار می‌گیرند رفتار غیرعادی از خودشان نشان می‌دهند.

از جمله این رفتارها می‌توان به نوسانات غیرطبیعی، افزایش دمای دستگاه، افزایش سرعت^۱ در دستگاه اشاره نمود.

برای مثال در [۱] سیگنال ارتعاشات یک بلبرینگ به عنوان یکی از اصلی‌ترین قطعات صنعتی از ابتدای شروع به کار تا زمان بروز اولین تخریب^۲ و تخریب کامل^۳ در مدت زمان ۶۹ روز جمع‌آوری شده است. «شکل ۲-۲»



شکل ۲-۲: سیگنال ارتعاش بلبرینگ از ابتدای فعالیت تا تخریب کامل [۱]

۱-۱-۲ اولین زمان خرابی

اولین زمانی را که دستگاه دچار نوسانات شدید می‌شود را به عنوان اولین زمان شروع فرایند تخریب در نظر می‌گیریم و آن را «FPT» می‌نامیم.

۲-۱-۲ عمر پایانی دستگاه

با افزایش دامنه نوسانات ثبت شده از دستگاه، تخریب دستگاه بیشتر شده و دستگاه گرم‌تر می‌شود. از این فرایند به عنوان یک بازخورد^۴ مثبت یاد می‌شود که افزایش گرما، نوسانات را بیشتر کرده و نوسانات بیشتر نیز گرمای دستگاه را افزایش می‌دهد. با تشدید هرچه بیشتر نوسانات، دستگاه به پایان عمر خود نزدیک‌تر شده و درنهایت

¹Noise

²First Prediction Time

³End of Life

⁴Feedback

از کار می‌افتد. زمان از کار فتادن نهایی دستگاه را به عنوان زمان پایان زندگی «EOF» تعریف می‌کنیم.

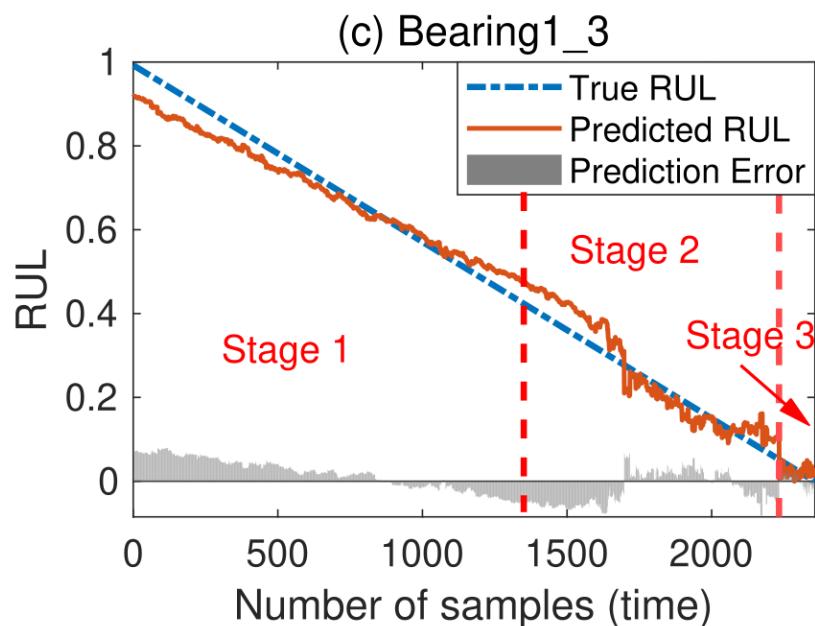
و درنهایت سیگنال RUL به صورت تفاضل این دوزمان تعریف می‌شود:

$$T_{RUL} = T_{EOF} - T_{FPT} \quad (1-2)$$

این سیگنال از جنس زمان است و مقدار RUL در این باز زمانی از رابطه زیر پیروی می‌کند:

$$RUL(t) = -t \quad (2-2)$$

برای مثال سیگنال RUL برای شکل «۲-۲» به صورت زیر محاسبه می‌شود:



شکل ۲-۳: سیگنال RUL شکل ۲-۲، [۱]

۲-۲ داده‌ها

برای پیش‌بینی عمر باقی‌مانده مفید، چندین مجموعه داده^۵ وجود دارد که در ادامه آنها را معرفی و بررسی می‌کنیم.

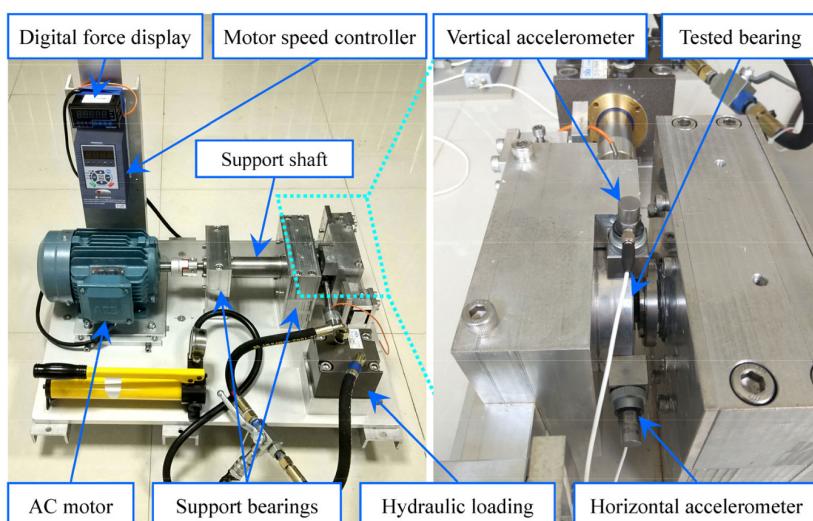
⁵Dataset

۱-۲-۲ مجموعه داده XJTU-SY

این مجموعه داده^۶ شامل داده های ثبت شده از ۱۵ بلبرینگ است که با انجام آزمایش های تخریب سریع، دچار تخریب شده اند. [۲]

این مجموعه داده توسط سیستمی که در شکل «۴-۲» نشان داده شده است، مشکل از یک موتور القایی جریان متناوب^۷، یک کنترل کننده سرعت موتور، یک محور^۸ پشتیبان، دو بلبرینگ پشتیبان (بلبرینگ های سنگین) و یک سیستم بارگذاری هیدرولیک تشکیل شده است.

این بستر آزمون برای انجام آزمایش های تخریب سریع شده بلبرینگ، تحت شرایط مختلف عملیاتی (نیروی شعاعی و سرعت چرخشی مختلف) طراحی شده است. نیروی شعاعی توسط سیستم بارگذاری هیدرولیک تولید شده و به محفظه بلبرینگ های آزمایش شده اعمال می شود و سرعت چرخش نیز توسط کنترلر سرعت موتور القایی AC تنظیم و نگه داشته می شود.



شکل ۴-۲: بستر تهیه مجموعه داده [۲] XJTU-SY

بلبرینگ های مورداستفاده در این آزمایش از نوع LDK UER204 هستند که پارامترهای دقیق آنها در جدول «۱-۲» آورده شده است.

این آزمایش، تحت ۳ شرط عملیاتی مختلف انجام شده است و هر ۵ بلبرینگ موجود در این آزمایش تحت این سه شرط عملیاتی قرار گرفته اند. این شرایط عملیاتی شامل موارد زیر هستند:

• ۲۱۰۰ دور در دقیقه^۹ (۳۵ هرتز) و بار دینامیکی ۱۲ کیلونیوتون

^۶ می توانید این مجموعه داده را از اینجا دریافت کنید: biaowang.tech/xjtu-sy-bearing-datasets/

⁷ Alternating Current

⁸ Shaft

⁹ RPM

جدول ۱-۲: پارامترهای بلبرینگ‌های آزمایش شده

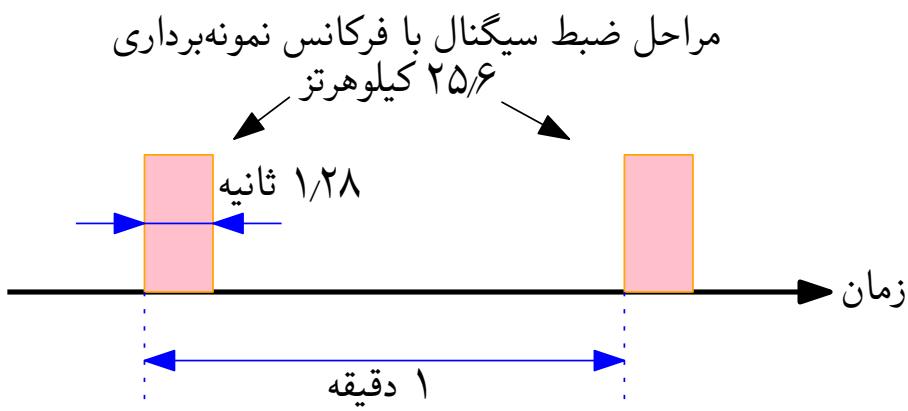
پارامتر	مقدار	پارامتر	مقدار	پارامتر
قطر مسیر بیرونی	۳۹/۸۰ mm	قطر مسیر داخلی	۲۹/۳۰ mm	
قطر متوسط بلبرینگ	۳۴/۵۵ mm	قطر توب	۷/۹۲ mm	
تعداد توب‌ها	۸	زاویه تماس	۰°	
بار استاتیک	۶,۶۵ kN	بار دینامیک	۱۲۸۲ kN	

• ۲۲۵° دور در دقیقه (۳۷/۵ هرتز) و بار دینامیکی ۱۱ کیلونیوتون

• ۲۴۰° دور در دقیقه (۴۰ هرتز) و بار دینامیکی ۱۰ کیلونیوتون

برای جمع‌آوری سیگنال‌های ارتعاشی بلبرینگ‌های آزمایش شده، همان‌طور که در شکل «۴-۲» نشان داده شده است، دو شتاب‌سنج از نوع PCB۳۵۲۰۳۳ در زاویه ۹۰ درجه بر روی محفظه بلبرینگ‌های آزمایش شده قرار داده شده است، یعنی یکی بر روی محور افقی و دیگری بر روی محور عمودی نصب شده است.

همچنین فرکانس نمونه‌برداری بر روی ۲۵/۶ کیلوهertz تنظیم شده است. همان‌طور که در شکل «۵-۲» نشان داده شده است، در مجموع ۳۲۷۶۸ نقطه داده (به مدت ۱/۲۸ ثانیه) برای هر نمونه‌برداری ثبت می‌شوند و دوره نمونه‌برداری برابر با ۱ دقیقه است.



شکل ۲-۵: تنظیمات نمونه‌برداری برای سیگنال‌های ارتعاشی

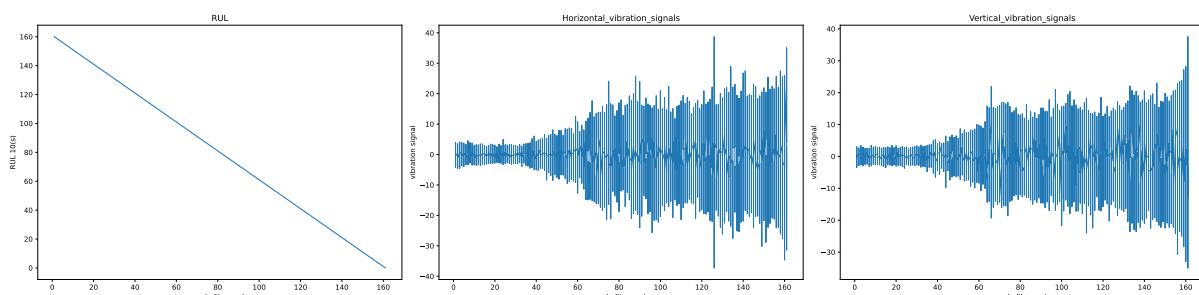
برای هر نمونه‌برداری، داده‌های به‌دست‌آمده در یک فایل csv ذخیره شده است که در آن ستون اول، سیگنال‌های ارتعاشی افقی و ستون دوم سیگنال‌های ارتعاشی عمودی را شامل می‌شود. جدول «۲-۲» اطلاعات دقیق هر بلبرینگ آزمایش شده، شامل تعداد فایل‌های csv، عمر بلبرینگ و عنصر خرایی را فهرست می‌کند.

نقطه EOF در این مجموعه داده $A_H \times 10$ در نظر گرفته شده است که A_H بیشینه دامنه سیگنال ارتعاش عمودی و افقی در حالت کاری طبیعی است.

جدول ۲-۲: اطلاعات مجموعه داده XJTU-SY

عامل خطا	مجموعه داده های بلبرینگ	طول عمر بلبرینگ	تعداد فایل ها	شرایط عملکرد
بیرونی	بلبرینگ ۱	۲ ساعت و ۳ دقیقه	۱۲۳	شایط ۱ ۳۵ هرتز، ۱۲ کیلونیوتون)
بیرونی	بلبرینگ ۲	۲ ساعت و ۴۱ دقیقه	۱۶۱	
بیرونی	بلبرینگ ۳	۲ ساعت و ۳۸ دقیقه	۱۵۸	
قفسه	بلبرینگ ۴	۲ ساعت و ۲ دقیقه	۱۲۲	
داخلی و بیرونی	بلبرینگ ۵	۵ دقیقه	۵۲	۱
داخلی	بلبرینگ ۱_۲	۸ ساعت و ۱۱ دقیقه	۴۹۱	شایط ۲ ۳۷/۵ هرتز، ۱۱ کیلونیوتون)
بیرونی	بلبرینگ ۲_۲	۲ ساعت و ۴۱ دقیقه	۱۶۱	
قفسه	بلبرینگ ۳_۲	۸ ساعت و ۵۳ دقیقه	۵۳۳	
بیرونی	بلبرینگ ۴_۲	۴۲ دقیقه	۴۲	
بیرونی	بلبرینگ ۵_۲	۵ ساعت و ۳۹ دقیقه	۳۳۹	
بیرونی	بلبرینگ ۱_۳	۴۲ ساعت و ۱۸ دقیقه	۲۵۳۸	شایط ۳ ۴۰ هرتز، ۱۰ کیلونیوتون)
داخلی، ساچمه، قفسه و بیرونی	بلبرینگ ۲_۳	۴۱ ساعت و ۳۶ دقیقه	۲۴۹۶	
داخلی	بلبرینگ ۳_۳	۶ ساعت و ۱۱ دقیقه	۳۷۱	
داخلی	بلبرینگ ۴_۳	۲۵ ساعت و ۱۵ دقیقه	۱۵۱۵	
بیرونی	بلبرینگ ۵_۳	۱ ساعت و ۵۴ دقیقه	۱۱۴	

در شکل های «۶-۲» و «۷-۲» نمونه ای از داده های این مجموعه داده آورده شده است.



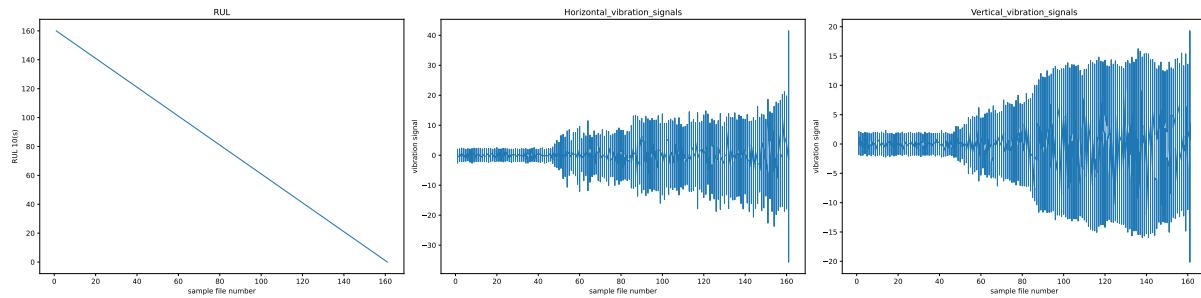
شکل ۲-۶: سیگنال های ارتعاش افقی و عمودی و RUL بلبرینگ ۱

۲-۲-۲ مجموعه داده PRONOSTIA

همانند مجموعه داده XJTY-SY این مجموعه داده^{۱۰} نیز، داده های ثبت شده از بلبرینگ توسط بستر آزمایشی نشان داده شده در شکل «۸-۲» است و امکان انجام آزمایش از ابتدای کار بلبرینگ تا زمان خرابی و شکست

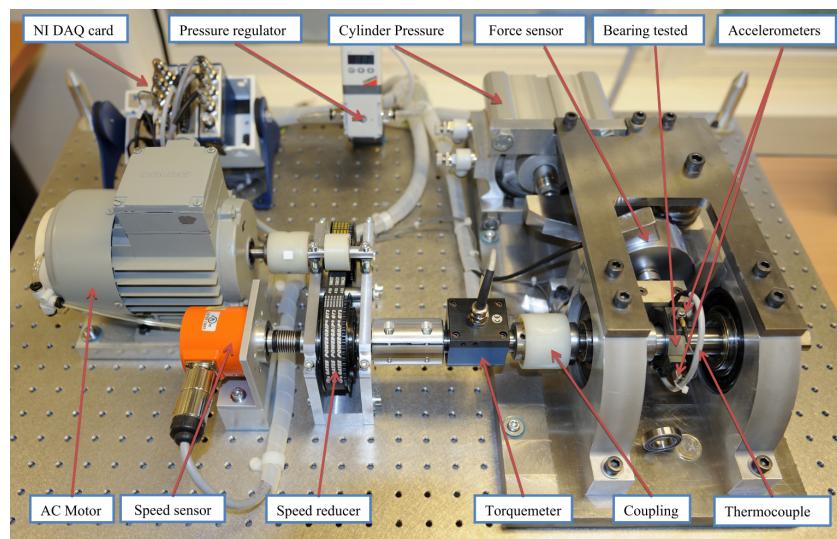
^{۱۰} می توانید این مجموعه داده را از اینجا دریافت کنید:

github.com/Lucky-Loek/ieee-phm-2012-data-challenge-dataset.git



شکل ۷-۲: سیگنال‌های ارتعاش افقی و عمودی و RUL بلبرینگ ۲-۲

کامل را فراهم می‌آورد. [۳]



شکل ۸-۲: بستر تهیه مجموعه داده PRONOSTIA [۳]

در این آزمایش، شرایط عملیاتی با اندازه‌گیری‌های لحظه‌ای ۱) نیروی شعاعی^{۱۱} اعمال شده بر بلبرینگ، ۲) سرعت چرخش شفتی که بلبرینگ را جایه‌جا می‌کند و ۳) گشتاور اعمال شده به بلبرینگ تعیین می‌شوند. هر یک از این سه اندازه‌گیری که به صورت آنالوگ انجام شده است، با فرکانسی برابر با ۱۰۰ هرتز به دست آمده است.

در این مجموعه داده، از دو نوع حسگر^{۱۲} برای تشخیص و توصیف عملیات تخریب استفاده شده است. حسگرهای:

- ارتعاش

- دما

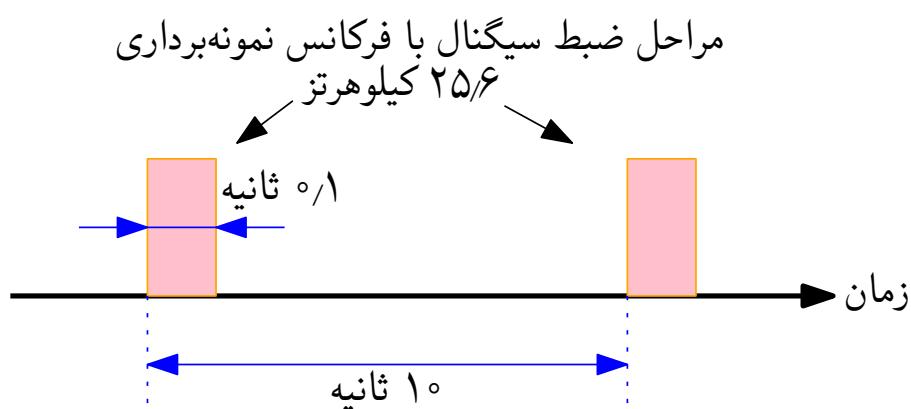
¹¹Radial Force

¹²Sensor

همانند مجموعه‌داده XJTU-SY، حسگرهای ارتعاش در این مجموعه آزمایشی نیز شامل دو شتاب‌سنج هستند که با زاویه 90° درجه نسبت به هم قرار دارند (اولی به صورتی عمودی و دومی به صورت افقی). این دو شتاب‌سنج به صورت شعاعی روی مسیر خارجی بلبرینگ قرار گرفته‌اند.

در این مجموعه آزمایشی علاوه بر حسگرهای ارتعاش، حسگرهای دما نیز وجود دارد. حسگر دما یک پروب از جنس پلاتینیم است که در داخل سوراخی نزدیک به حلقه خارجی بلبرینگ قرار می‌گیرد. RTD

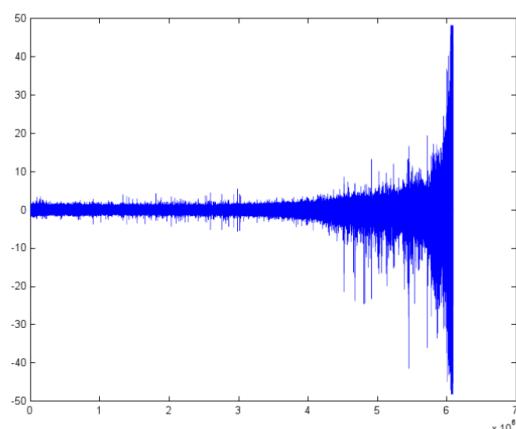
حسگرهای شتاب، نمونه‌ها را با فرکانس $25/6$ کیلوهرتز و حسگر دما با فرکانس 1° هرتز ثبت می‌کنند. یعنی سیگنال‌های ارتعاشی 256° نمونه ($\frac{1}{10}$ ثانیه) در هر 1° ثانیه ضبط می‌شوند و سیگنال‌های دما، 600° نمونه هر دقیقه ضبط می‌شوند.



شکل ۹-۲: تنظیمات نمونه‌برداری سیگنال‌ها در این آزمایش

در تهیه این مجموعه داده، برای جلوگیری از انتشار آسیب به کل بستر آزمایش، آزمایش‌ها زمانی متوقف شدند که دامنه سیگنال ارتعاش از 20° فراتر رفت.

شکل «۱۰-۲» مثالی است از آنچه می‌توان بر روی اجزای بلبرینگ قبل و بعد از یک آزمایش مشاهده کرد و همچنین یک سیگنال خام ارتعاش جمع‌آوری شده در طول یک آزمایش کامل را نشان می‌دهد.



شکل ۱۰-۲: سیگنال خام تهیه شده در این آزمایش و بلبرینگ تخریب شده، [۳]

ذکر این نکته الزامی است که بلبرینگ‌ها رفتارهای بسیار متفاوتی را در زمان تخریب نشان می‌دهد که منجر به تفاوت در زمان آزمایش و تخریب می‌شود.

این آزمایش نیز تحت سه شرط عملیاتی مختلف انجام شده است:

• ۱۸۰۰ دور در دقیقه و بار دینامیکی ۴ کیلونیوتون

• ۱۶۵۰ دور در دقیقه و بار دینامیکی ۴/۲ کیلونیوتون

• ۱۵۰۰ دور در دقیقه و بار ۵ کیلونیوتون

داده‌های جمع‌آوری شده از این آزمایش به صورت جدول «۳-۲» تقسیم‌بندی می‌شود
جدول ۳-۲: تقسیم‌بندی داده‌های جمع‌آوری شده در مجموعه داده PRONOSTIA

مجموعه داده‌ها	شرایط عملیاتی ۱	شرایط عملیاتی ۲	مجموعه داده‌ها
مجموعه آموزشی	بلبرینگ ۱_۳	بلبرینگ ۱_۲	بلبرینگ ۱_۱
	بلبرینگ ۲_۳	بلبرینگ ۲_۲	بلبرینگ ۲_۱
مجموعه آزمون	بلبرینگ ۳_۳	بلبرینگ ۳_۲	بلبرینگ ۳_۱
		بلبرینگ ۴_۲	بلبرینگ ۴_۱
		بلبرینگ ۵_۲	بلبرینگ ۵_۱
		بلبرینگ ۶_۲	بلبرینگ ۶_۱
		بلبرینگ ۷_۲	بلبرینگ ۷_۱

هر دو مجموعه داده‌های آموزشی و آزمایشی حاوی فایل‌هایی csv ارتعاش به نام acc_xxxxxx.csv و فایل‌های دما به نام temp_xxxxxx.csv هستند.

همه فایل‌های csv ضبط شده از قالب زیر تبعیت می‌کنند:

جدول ۴-۲: مشخصات داده‌های ضبط شده در فایل‌های csv

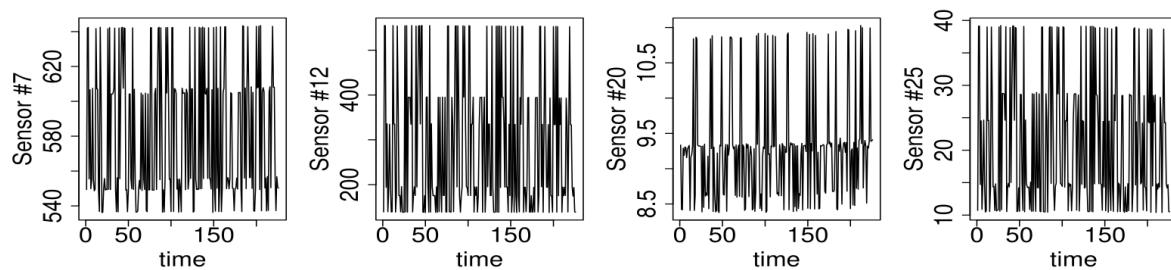
ستون	۱	۲	۳	۴	۵	۶
سیگنال ارتعاش	ساعت	دقیقه	ثانیه	میکروثانیه	حسگر افقی	حسگر عمودی
سیگنال دما	ساعت	دقیقه	ثانیه	x/۰	حسگر RTD	

۳-۲-۲ مجموعه داده C-MAPSS

برخلاف دو مجموعه داده قبلی، این مجموعه داده^{۱۲}، داده‌های تهیه شده از موتور هوایی جت از ابتدای کارکرد تا زمان تخریب است. [۷]

این مجموعه داده، شامل چندین سری زمانی چندمتغیره است. هر مجموعه داده به زیرمجموعه‌های آموزشی و آزمایشی تقسیم می‌شود. داده‌ها از موتورهای متفاوتی تهیه شده است. هر موتور با درجات مختلفی از سایش اولیه و تغییرات تولیدی که برای کاربر ناشناخته است، شروع به کار می‌کند. این سایش و تغییرات به عنوان وضعیت طبیعی در نظر گرفته می‌شوند و به عنوان شرایط خطا تلقی نمی‌شوند.

در این مجموعه داده، سه تنظیمات عملیاتی وجود دارد که تأثیر قابل توجهی بر عملکرد موتور دارند و جمع‌آوری داده‌ها بر اساس این تنظیمات انجام شده است. برخلاف دو مجموعه داده قبلی، داده‌های این مجموعه به نویز حسگرها آلوده شده است.



شکل ۱۱-۲: چند سیگنال تصادفی خام جمع‌آوری شده توسط حسگرهای در موتور از مجموعه داده آموزشی FD002 [۴]

موتور در ابتدای هر سری زمانی به طور عادی عمل می‌کند و در یک نقطه از سری دچار خطا می‌شود. در مجموعه آموزشی، خطا به شدت افزایش می‌یابد تا زمانی که سیستم به طور کامل تخریب شود. اما در مجموعه آزمایشی، سری زمانی کمی قبل از خرابی سیستم خاتمه می‌یابد.

داده‌های جمع‌آوری شده توسط ۲۶ حسگر، به صورت یک فایل متنی فشرده شده با فرمت txt ارائه شده است؛ بنابراین هر فایل دارای ۲۶ ستون است که هر کدام از این ستون‌ها به صورت زیر معرفی می‌شود:

۱. شماره واحد

۲. زمان (برحسب تعداد چرخه^{۱۴})

۳. تنظیمات عملیاتی

^{۱۳} می‌توانید این مجموعه داده را از اینجا دریافت کنید:

data.nasa.gov/Aerospace/CMAPSS-Jet-Engine-Simulated-Data/ff5v-kuh6/about_data

¹⁴Cycle

۴. تنظیمات عملیاتی ۲

۵. تنظیمات عملیاتی ۳

۶. مقدار اندازه‌گیری شده توسط حسگر شماره ۱

۷. مقدار اندازه‌گیری شده توسط حسگر شماره ۲

۸. مقدار اندازه‌گیری شده توسط حسگر شماره ۳

... ۹

۱۰. مقدار اندازه‌گیری شده توسط حسگر شماره ۲۶

در جدول «۵-۲» اطلاعات دقیقی از این مجموعه‌داده آورده شده است.

جدول ۵-۲: اطلاعات زیرمجموعه‌ها در مجموعه‌داده C-MAPSS

FD004	FD003	FD002	FD001	
۲۴۹	۱۰۰	۲۶۰	۱۰۰	تعداد موتورها در مجموعه آموزش
۲۴۸	۱۰۰	۲۵۹	۱۰۰	تعداد موتورها در مجموعه آزمون
۶	۱	۶	۱	تعداد شرایط عملیاتی
۲	۲	۱	۱	تعداد حالت‌های خطا

۳-۲ شبکه عصبی ترانسفرمر

برای اولین بار در سال ۲۰۱۷ مفهومی به نام مکانیزم توجه^{۱۵} در مقاله‌ای تحت عنوان «Attention is All» در مقاله‌ای تحت عنوان «You Need»^{۱۶} توسط شرکت گوگل با کاربرد در زمینه پردازش زبان طبیعی معرفی شد [۸].

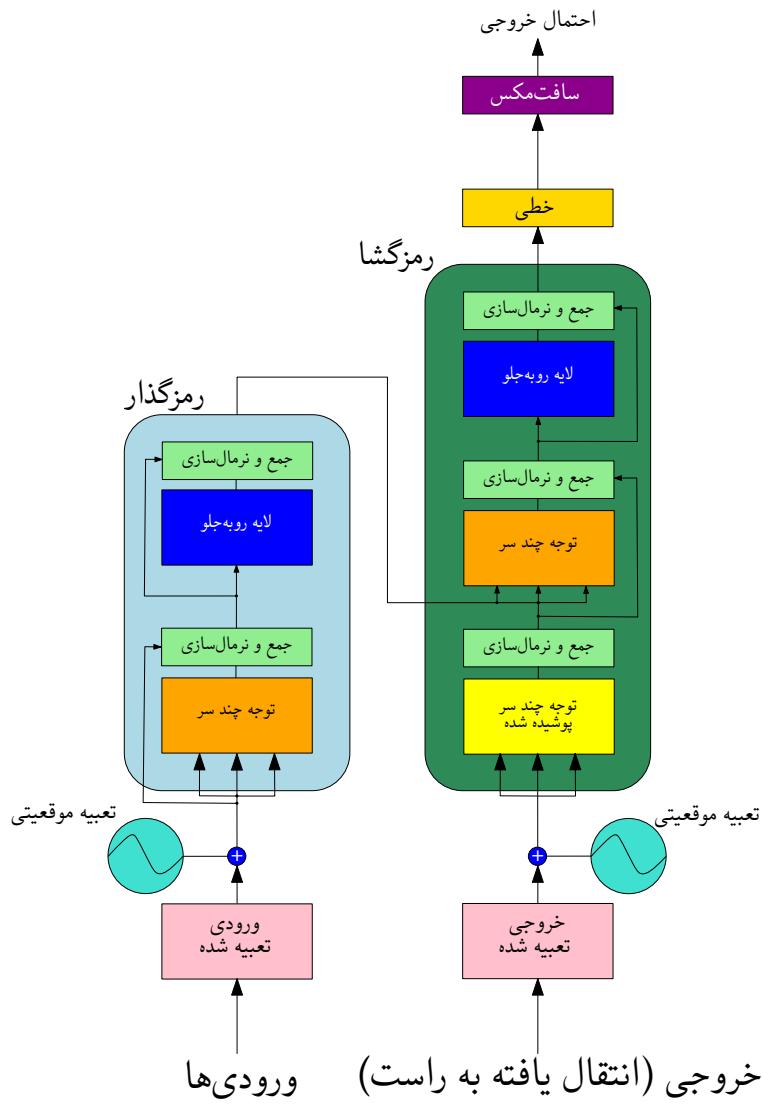
در این مقاله، ساختار جدیدی از یک شبکه عصبی نیز معرفی شد که بر پایه مکانیزم توجه کار می‌کند و توانست خیلی زود جایگزین مناسبی برای مدل‌های سنتی قدیمی و ساختارهای RNN شود. در ادامه به بررسی جزئی معماری این ساختار می‌پردازیم.

¹⁵Attention

¹⁶Natural Language Processing

۱-۳-۲ ساختار کلی شبکه

شبکه ترنسفرمر از یک ساختار رمزگذار^{۱۷} - رمزگشا^{۱۸} پیروی می‌کند. شکل ۱۲-۲



شکل ۱۲-۲: ساختار کلی شبکه ترنسفرمر

۲-۳-۲ ورودی تعییه شده

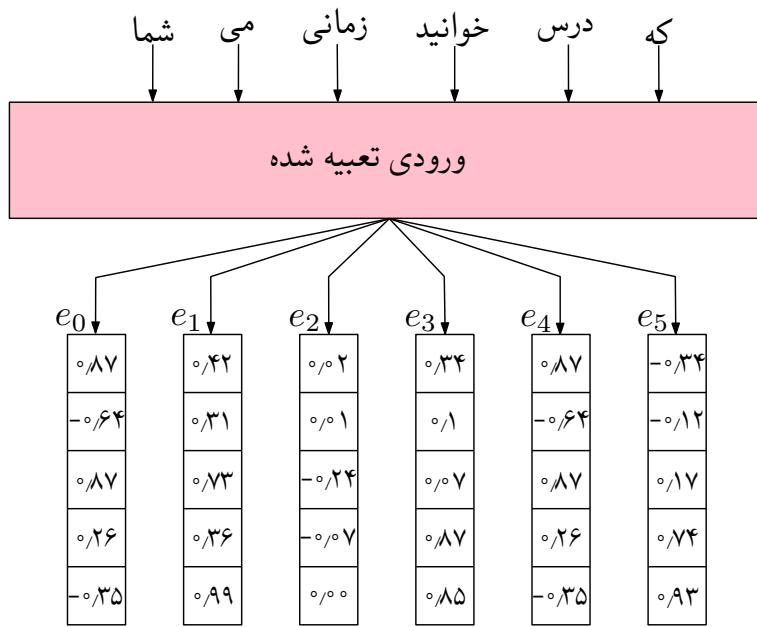
برای توضیح این قسمت از شبکه، فرض می‌شود که می‌خواهیم یک جمله ناقص را به عنوان ورودی به شبکه بدهیم و شبکه باید آن را تکمیل کند. برای مثال فرض شود که جمله ورودی ما به صورت زیر است:

”زمانی که شما درس می‌خوانید...”

¹⁷Encoder

¹⁸Decoder

اولین مرحله در تمامی الگوریتم‌های یادگیری ماشین که ورودی آن‌ها کلمه است، تبدیل کلمات به بردارهای عددی است. وظیفه این مرحله با بلوک ورودی تعبیه شده است. «شکل ۱۳-۲»



شکل ۱۳-۲: تبدیل کلمات به بردار

۳-۳-۲ تعبیه موقعیتی

برخلاف سایر شبکه‌ها مانند RNN و LSTM که ورودی‌ها به صورتی ترتیبی و پشت‌سرهم وارد می‌شوند، در شبکه ترنسفرمر، ورودی‌ها به صورت موازی باهم و هم‌زمان وارد لایه تعبیه شده می‌شوند؛ بنابراین نیاز است که ترتیب و جایگاه ورودی‌ها نسبت به یکدیگر مشخص باشد. ترتیب ورودی‌ها بر حسب دوتابع سینوسی و کسینوسی بر حسب رابطه‌های زیر تعیین می‌شود.

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{1000 \frac{2i}{d}}\right) \quad (3-2)$$

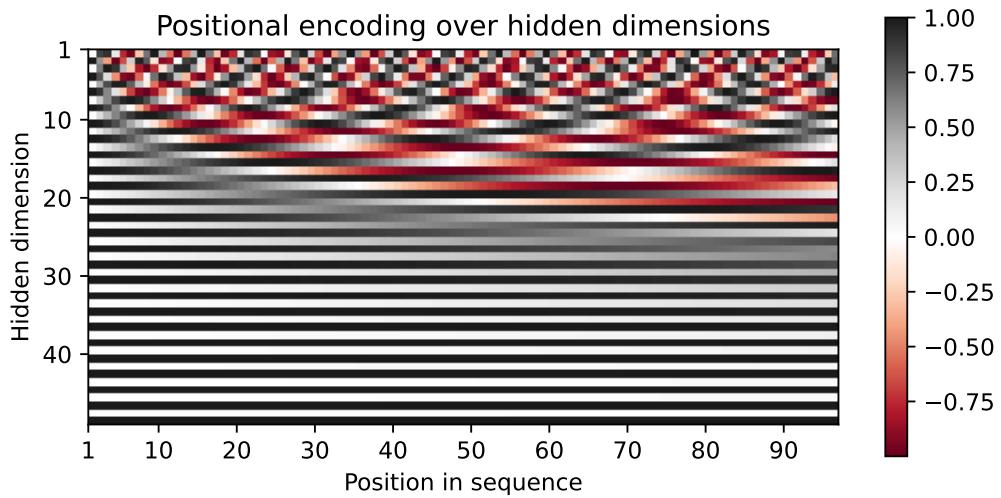
$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{1000 \frac{2i+1}{d}}\right) \quad (4-2)$$

ورودی‌هایی با نمایه^{۱۹} «زوج، از رابطه ۳-۲» و نمایه فرد از رابطه «۴-۲» استفاده می‌کنند.

در روابط تعبیه موقعیتی، مقدار pos برابر است با جایگاه کلمه، مقدار d برابر است با طول بردار تعبیه شده (در مثال ما $d = 5$) و مقدار i برابر است با جایگاه‌های هر بردار.

¹⁹Index

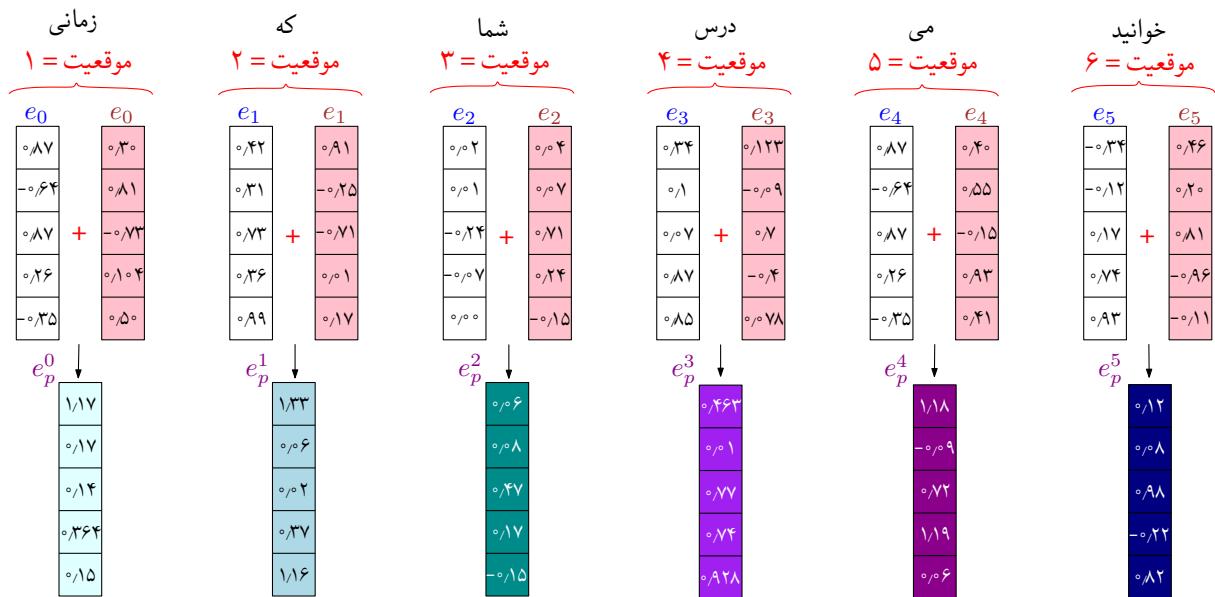
با رسم روابط تعییه موقعیتی، خروجی ای مانند شکل «۱۴-۲» حاصل می‌شود.



شکل ۱۴-۲: خروجی گرافیکی بلوک تعییه موقعیتی به ازای $d = 48$ و $i = 96$

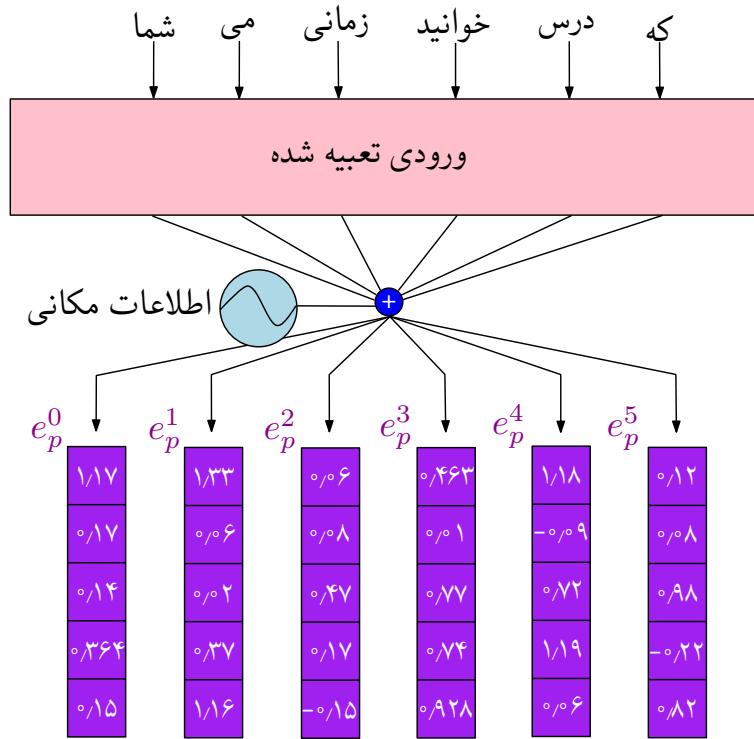
سپس مقادیر ساخته شده توسط روابط لایه تعییه موقعیتی، با بردارهای ورودی جمع می‌شوند. «شکل ۱۵-۲»

«۱۵-۲



شکل ۱۵-۲: جمع بردارهای ورودی با بردارهای موقعیتی تعییه شده

و درنهایت می‌توان عملکرد دو بلوک (۱) ورودی تعییه شده و (۲) تعییه موقعیتی را به صورت شکل «۱۶-۲» نمایش داد.



شکل ۱۶-۲: عملیات ورودی تعبیه شده و تعبیه موقعیتی

۴-۳-۲ توجه چند سر

mekanizm توجه، به مدل کمک می‌کند تا به ورودی‌های مهم توجه بیشتری شود. بلوک توجه چند سر^{۲۰} متشکل است از چندین لایه توجه به خود^{۲۱}. وظیفه این لایه به دست آوردن و درک وابستگی‌های مهم در ورودی است. برای مثال فرض شود ورودی شبکه جمله زیر است:

”شب‌هنجام که **ماه** را در آسمان دیدم، به یاد **ماه** رویت افتادم.“

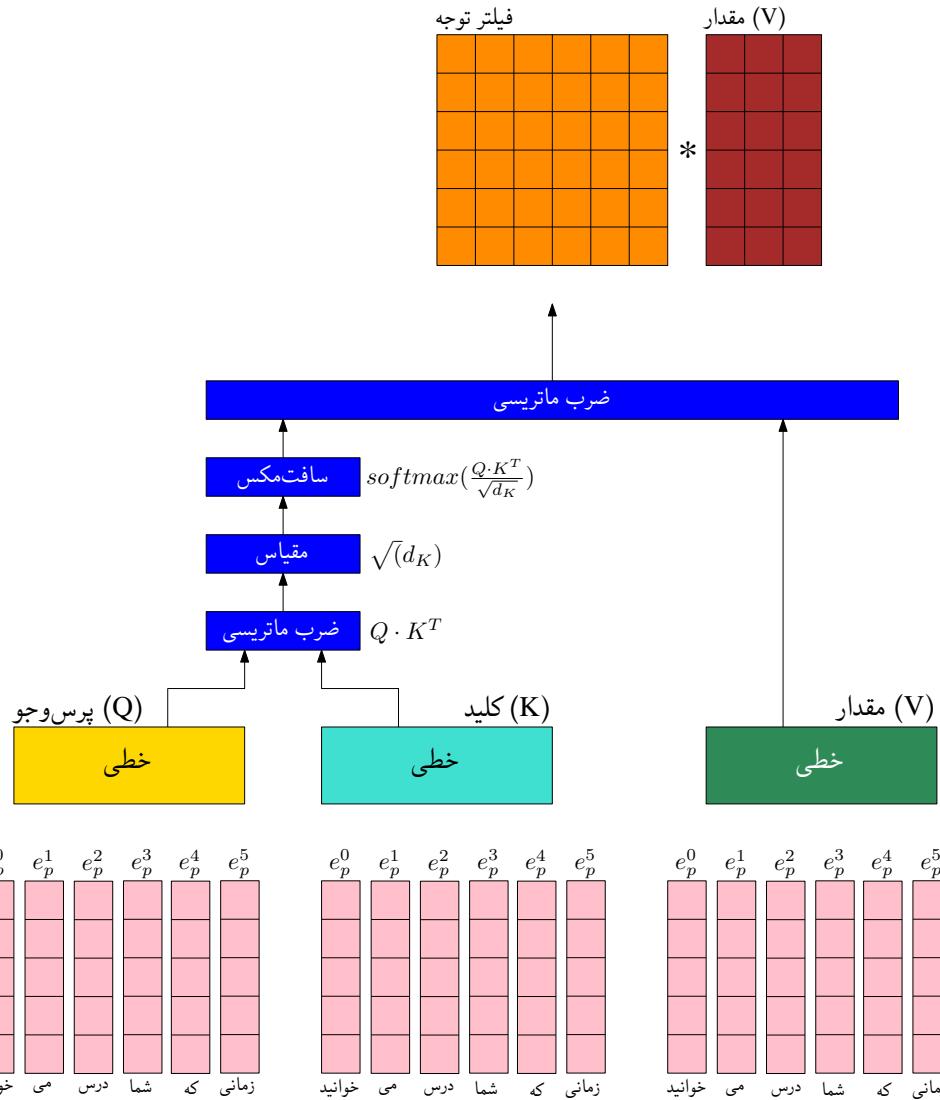
در این جمله دو بار کلمه ”ماه“ به کار رفته است که اولین آن به معنی قمر آسمانی و دومین آن به معنی زیبایی است.

مدل چگونه باید تشخیص دهد که کدام ”ماه“ به معنی قمر و کدام به معنی زیبایی است؟ لایه توجه به خود در اینجا به کمک می‌آید و وابستگی کلمه ”ماه“ را با سایر کلمات جمله بررسی می‌کند و بر اساس نقشه توجهی که به دست می‌آورد می‌تواند تشخیص دهد که هر کدام از ”ماه“‌ها به چه معناست.

عملیاتی که برای به دست آوردن نقشه‌های توجه انجام می‌شود، در شکل ۱۷-۲ خلاصه می‌شود.

²⁰Multi-Head Attention

²¹Self-Attention



شکل ۱۷-۲: لایه توجه به خود

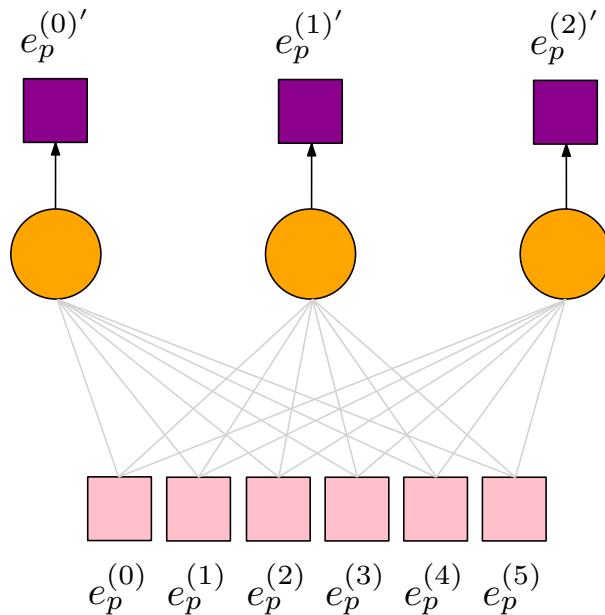
در ابتدا از بردارهای به دست آمده از لایه‌های تعبیه شده، ^۳ نمونه می‌سازیم. بردارهای به دست آمده برای هر کلمه، به یک لایه شبکه عصبی خطی با تعداد نورون‌های دلخواه وارد می‌شود. «شکل ۱۸-۲» پس از آموزش شبکه خطی و به دست آمدت بهترین وزن‌ها برای شبکه، خروجی سه شبکه خطی را به ترتیب ماتریس‌های پرس و جو ^{۲۲} (Q)، کلید ^{۲۳} (K) و مقدار ^{۲۴} (V) می‌نامیم. معیار توقف آموزش شبکه خطی، میزان شباهت بین ماتریس‌ها است که از رابطه «۲-۵» می‌توان آن را به دست آورد:

$$Attention(Q, K, V) = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d_K}}\right) \cdot V \quad (5-2)$$

²²Query

²³Key

²⁴Value



شکل ۱۸-۲: لایه خطی

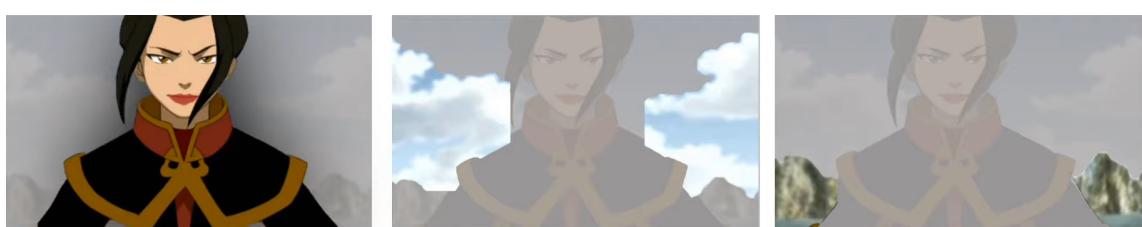
و در نهایت فیلتر توجه به دست آمده را در ماتریس V ضرب می‌کنیم و مقدار فیلترها به دست می‌آید.

شکل ۱۹-۲ مثالی از یک فیلتر توجه و در نهایت ضرب فیلتر در ورودی و ایجاد تصویر نهایی را نمایش می‌دهد.

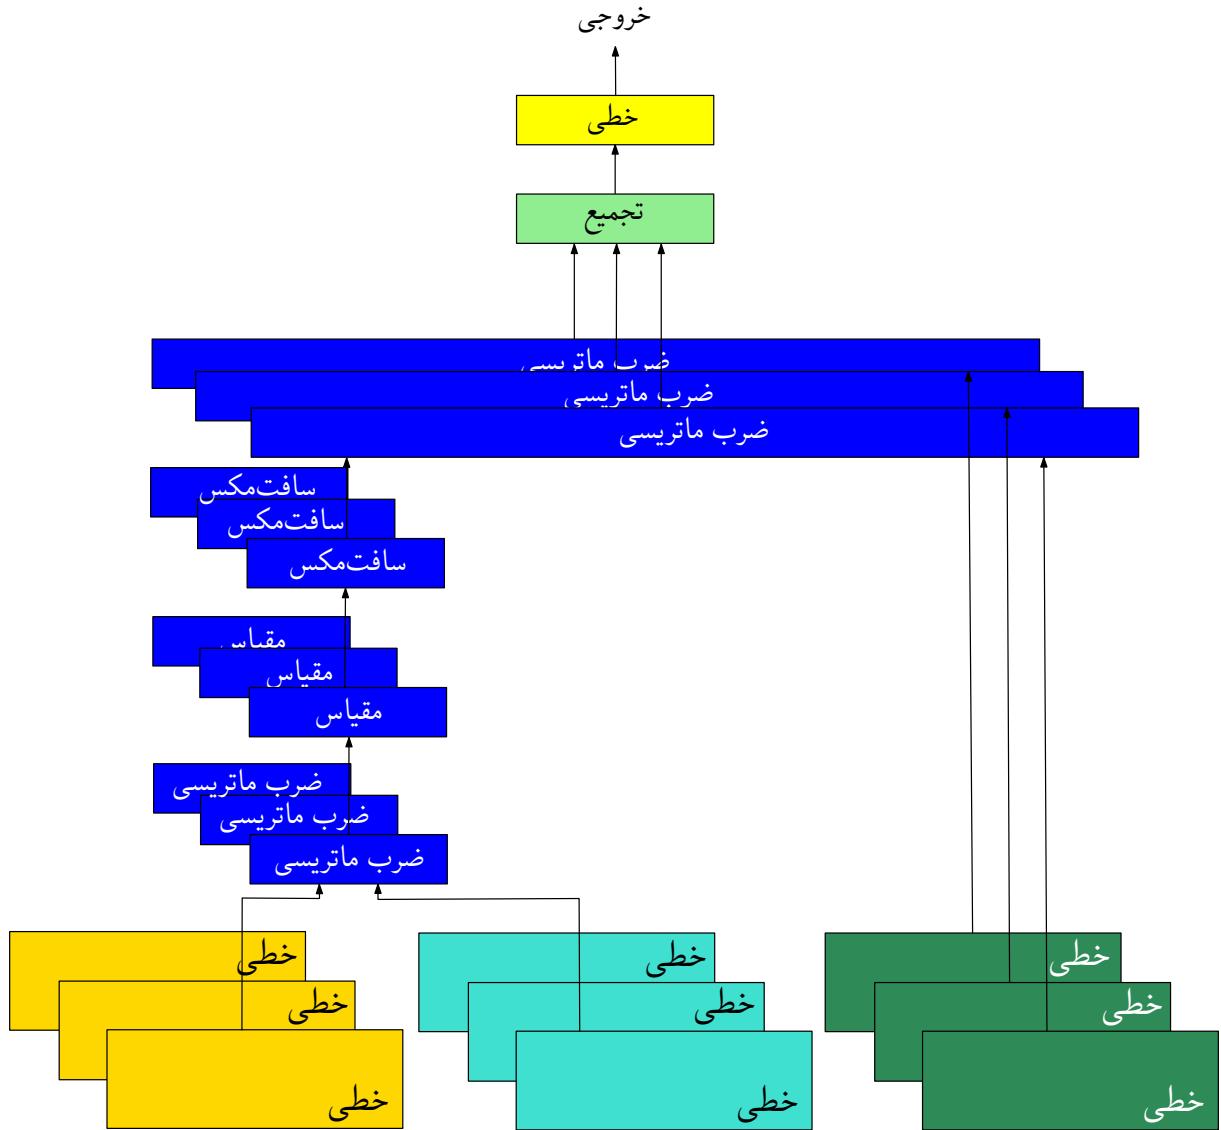


شکل ۱۹-۲: فرایند اعمال فیلتر توجه به تصویر

مراحل توضیح داده شده برای به دست آوردن صرفاً یک فیلتر توجه است. برای به دست آوردن بهترین نتیجه در خروجی، نیاز است که فیلترهای توجه مختلفی داشته باشیم. یا به عبارتی دیگر توجه‌های چند سر داشته باشیم و توجه‌ها را در همه جای جمله (یا تصویر) به دست آوریم. با قراردادن چند لایه از لایه توجه به خود در کنار هم «شکل ۲۰-۲» می‌توان لایه توجه چند سر را ایجاد نمود و فیلترهای توجه مختلفی را تولید کرد. «شکل ۲۱-۲»



شکل ۲۰-۲: فیلترهای توجه مختلف در تصویر



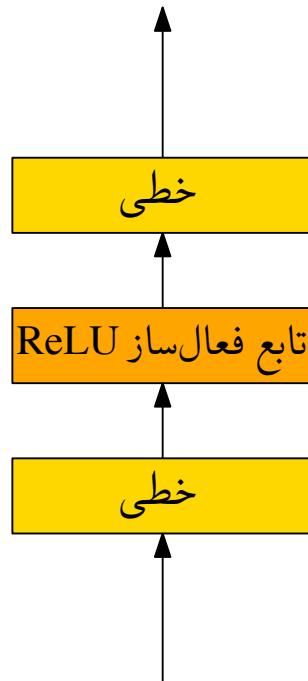
شکل ۲-۲۱: لایه توجه چند سر

۲-۳-۵ رویه جلو

لایه رویه جلو متشکل است از دو لایه خطی که در قسمت های قبل توضیح داده شد و یک لایه تابع فعال ساز^{۲۵} رلو^{۲۶} «شکل ۲-۲۲».

²⁵ Activation Function

²⁶ ReLU



شکل ۲۲-۲: لایه روبه‌جلو

۶-۳-۲ لایه خطی رمزگشا

پس از تشکیل فیلترهای توجه در بلوک رمزگذار، ۲ نمونه مشابه از آن ساخته می‌شود. این دو نمونه ماتریس‌های Q و K برای بلوک رمزگشا خواهند بود و ماتریس سوم که ماتریس V است، همانند توضیحات قسمت‌های قبل به صورت مستقیم وارد بلوک رمزگذار شده و درنهایت این سه ماتریس به صورت همزمان وارد به لایه توجه چند سر موجود در بلوک رمزگذار می‌شوند.

۷-۳-۲ لایه خطی رمزگذار

درنهایت در بلوک رمزگذار یک لایه خطی وجود دارد که وظیفه طبقه‌بندی کلمات ورودی را دارد. تعداد نورون‌های این لایه برابر است با تعداد کلمات موجود در کلمه. وظیفه این لایه مشخص کردن بهترین خروجی و خروجی برنده که می‌تواند به عنوان کلمه بعدی برای تکمیل جمله پیشنهاد داده شود است.

برای مثال اگر جمله‌ای که از ابتدا به عنوان مثال بیان کردیم را به شبکه بدھیم می‌توانیم انتظار داشته باشیم که یکی از خروجی‌های شبکه به صورت زیر تولید شود:

“زمانی که شما درس می‌خوانید، **بیشترین تمرکز را دارید.**”

فصل ۳

کارهای پیشین

ماشین‌های دوار به طیف وسیعی از ماشین‌ها اطلاق می‌شود که حول یک محور می‌چرخند، مانند توربین‌ها، ژنراتورها، پمپ‌ها، کمپرسورها و موتورها [۹]. این ماشین‌ها در بسیاری از زمینه‌ها مانند تولید برق، نفت و گاز، حمل و نقل کاربردهای گسترده‌ای دارند [۱۰]. بلبرینگ^۱ به عنوان یکی از مهم‌ترین ابزارهای صنعتی، با تسهیل چرخش شفت از طریق یک رابط کم اصطکاک بین شفت و محفظه آن و کاهش سایش و پارگی اجزای ماشین، نقش مهمی در تضمین عملکرد روان و کارآمد ماشین‌های دوار دارد [۱۱]. با این حال، بلبرینگ‌ها در طول زمان به دلیل بار زیاد، روانکاری ناکافی و آلدگی تخریب می‌شوند [۱۲]. تخریب بلبرینگ‌ها می‌تواند منجر به لرزش و نویز بیش از حد، بازده کم و مصرف انرژی بالا شود و اگر کنترل نشود، می‌تواند منجر به خرابی‌های فاجعه‌بار شود که باعث تعمیرات پرهزینه، ازکارافتاون ماشین‌آلات شود [۱۳] بنابراین؛ نظارت و پیش‌بینی وضعیت سلامت و عمر مفید باقی‌مانده بلبرینگ‌ها برای کاهش زمان ازکارافتاون دستگاه بسیار مهم است.

به‌طورکلی روش‌هایی پیش‌بینی RUL رامی می‌توان به ۳ دسته تقسیم کرد:

- روش‌های مبتنی بر مدل

- روش‌های مبتنی بر داده

- روش‌های ترکیبی

روش‌های مبتنی بر مدل، نیازمند مدل‌سازی دقیق دینامیک مسئله و اطلاع از جزئیات دقیق ابزار صنعتی مورد بررسی است. ساختار تجهیزات صنعتی در مقیاس‌های بزرگ با روابط غیرخطی بین سیستم‌ها و قطعات مختلف پیچیده می‌شود که اغلب ارائه یک مدل دقیق از آن کار بسیار دشواری است. هدف اصلی در روش‌های

¹Bearing

مبتنی بر داده، ایجاد یک رابطه نگاشت بین فضای ویژگی‌های ورودی و RUL هدف است. این روش نیازی به شناخت دقیق فیزیکی مدل مکانیکی ندارد.

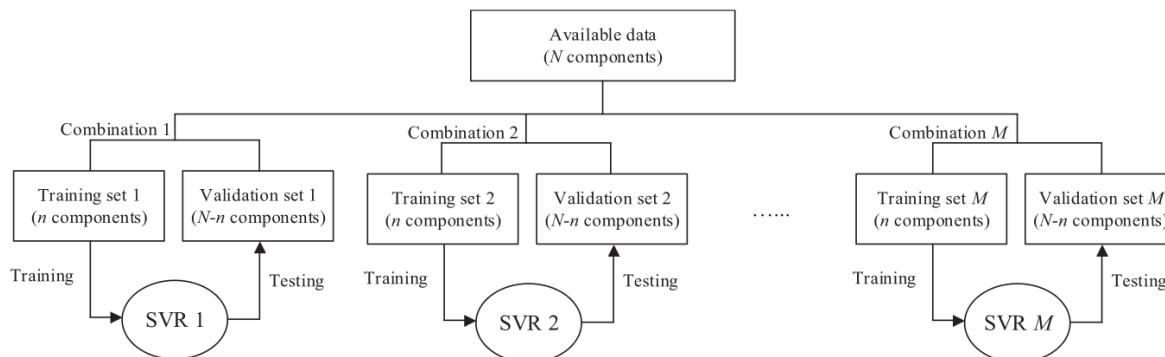
روش‌های مبتنی بر داده به طور گستره‌ای برای پیش‌بینی RUL بلبرینگ‌ها مورداستفاده قرار گرفته‌اند، زیرا می‌توانند پیش‌بینی را با استفاده از داده‌های نظارت بر وضعیت، بدون دانش و شناخت قبلی نسبت به سیستم انجام دهند. روش‌های مبتنی بر داده را می‌توان به دو دسته گروه‌بندی کرد:

۱. روش‌های مبتنی بر یادگیری ماشین سنتی

۲. روش‌های مبتنی بر یادگیری عمیق

روش‌های یادگیری ماشین سنتی شامل رگرسیون بردار پشتیبان^۲ [۱۴]، فرایند گاوی^۳ [۱۵]، یادگیری گروهی^۴ [۱۶]، مدل مارکوف^۵ [۱۷] و موارد دیگر است.

به عنوان مثال، منگ و همکاران [۵] یک رویکرد رگرسیون برداری چند پشتیبانی را برای به دست آوردن پارامترهای مدل فرعی بهینه برای پیش‌بینی RUL بلبرینگ‌ها معرفی کرد. آن‌ها از مدلی مانند شکل «۱-۳» استفاده کردند.



شکل ۱-۳: مدل ارائه شده مبتنی بر بردارهای پشتیبان در [۵]

پس از به دست آوردن پارامترهای مدل بهینه، یک سازوکار به روزرسانی وزن خودکار برای ارزیابی مناسب بودن هر مدل فرعی برای عملکرد پیش‌بینی قوی‌تر پیشنهاد شد. در این کار از مجموعه داده CMAPASS برای ارزیابی عملکرد پیش‌بینی روش ارائه شده استفاده شد و نتایج ارائه شده «شکل ۲-۳» نشان می‌دهد که داد که روش ارائه شده، ۹۸/۱۴ به دست آمده است.

منگ و همکاران [۶] مدل مارکوف خاکستری را با نظریه طیف فرکتال^۶ ادغام کرد تا مسیر تخریب

²Support Vector Regression

³Gaussian Process

⁴Ensemble Learning

⁵Markov Model

⁶Fractal Spectrum

Prediction errors for component 17.

Model	MRE	RMSE	Score	Convergence
SVR 1	0.1538	0.1129	1.9882	192.8072
SVR 2	0.1666	0.1371	2.3389	<u>163.3994</u>
SVR 3	0.1313	<u>0.0777</u>	<u>1.4517</u>	215.2919
SVR 4	0.2333	0.1606	2.8810	196.4635
SVR 5	0.1704	0.1177	2.0641	184.7899
SVR 6	0.1603	0.1255	2.1551	181.1349
SVR 7	0.2481	0.1529	2.6155	313.4165
SVR 8	0.1817	0.1031	1.8914	232.6900
SVR 9	0.2473	0.1326	2.3010	339.7910
SVR 10	0.1806	0.1328	2.2448	277.0041
Multi-SVR fusion	0.1283	0.1160	1.8548	165.6945

شکل ۲-۳: نتایج ارائه شده [۵]

بلبرینگ‌ها را پیش‌بینی کند. برای انجام پیش‌بینی در این مقاله از مجموعه داده PRONOSTIA استفاده شده است. روش ارائه شده با ویژگی ذرات مورفولوژی تعمیم‌یافته مقایسه شده است که نشان داده روش ارائه شده می‌تواند RMSE را تا ۴ درصد کاهش دهد. نتایج این روش در شکل «۳-۳» آورده شده است.

Prediction method	Component	RMSE(%)
GMMP	IMF1	13.38
	IMF2	14.55
Fractal spectrum parameters	IMF1	9.33
	IMF2	10.53

شکل ۳-۳: نتایج ارائه شده [۶]

فصل ۴

چالش‌ها و نوآوری‌ها

در این فصل نتایج جدید به دست آمده در پایان‌نامه توضیح داده می‌شود. در صورت نیاز می‌توان نتایج جدید را در قالب چند فصل ارائه نمود. همچنین در صورت وجود پیاده‌سازی، بهتر است نتایج پیاده‌سازی را در فصل مستقلی پس از این فصل قرار داد.

فصل ۵

نتیجه‌گیری

در این فصل، ضمن جمع‌بندی نتایج جدید ارائه شده در پایان‌نامه یا رساله، مسائل باز باقی‌مانده و همچنین پیشنهادهایی برای ادامه‌ی کار ارائه می‌شوند.

Bibliography

- [1] Y. Wei and D. Wu. Conditional variational transformer for bearing remaining useful life prediction. *Advanced Engineering Informatics*, 59:102247, 2024.
- [2] B. Wang, Y. Lei, N. Li, and N. Li. A hybrid prognostics approach for estimating remaining useful life of rolling element bearings. *IEEE Transactions on Reliability*, 69(1):401–412, 2018.
- [3] P. Nectoux, R. Gouriveau, K. Medjaher, E. Ramasso, B. Chebel-Morello, N. Zerhouni, and C. Varnier. Pronostia: An experimental platform for bearings accelerated degradation tests. In *IEEE International Conference on Prognostics and Health Management, PHM’12.*, pages 1–8. IEEE Catalog Number: CPF12PHM-CDR, 2012.
- [4] Q. Wang, S. Zheng, A. Farahat, S. Serita, and C. Gupta. Remaining useful life estimation using functional data analysis. In *2019 ieee international conference on prognostics and health management (icphm)*, pages 1–8. IEEE, 2019.
- [5] Y. Li, X. Huang, C. Zhao, and P. Ding. A novel remaining useful life prediction method based on multi-support vector regression fusion and adaptive weight updating. *ISA transactions*, 131:444–459, 2022.
- [6] Z. Meng, J. Li, N. Yin, and Z. Pan. Remaining useful life prediction of rolling bearing using fractal theory. *Measurement*, 156:107572, 2020.
- [7] A. Saxena, K. Goebel, D. Simon, and N. Eklund. Damage propagation modeling for aircraft engine run-to-failure simulation. In *Proceedings of the 1st International Conference on Prognostics and Health Management (PHM08)*, Denver, CO, Oct 2008.
- [8] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

- [9] M. Yu, Y. Zhang, and C. Yang. Rolling bearing faults identification based on multiscale singular value. *Advanced Engineering Informatics*, 57:102040, 2023.
- [10] Y. Lei, J. Lin, Z. He, and M. J. Zuo. A review on empirical mode decomposition in fault diagnosis of rotating machinery. *Mechanical systems and signal processing*, 35(1-2):108–126, 2013.
- [11] D.-T. Hoang and H.-J. Kang. A survey on deep learning based bearing fault diagnosis. *Neurocomputing*, 335:327–335, 2019.
- [12] Z. Liu and L. Zhang. A review of failure modes, condition monitoring and fault diagnosis methods for large-scale wind turbine bearings. *Measurement*, 149:107002, 2020.
- [13] D. Neupane and J. Seok. Bearing fault detection and diagnosis using case western reserve university dataset with deep learning approaches: A review. *Ieee Access*, 8:93155–93178, 2020.
- [14] M. M. Islam, A. E. Prosvirin, and J.-M. Kim. Data-driven prognostic scheme for rolling-element bearings using a new health index and variants of least-square support vector machines. *Mechanical Systems and Signal Processing*, 160:107853, 2021.
- [15] J. Zhou, Y. Qin, D. Chen, F. Liu, and Q. Qian. Remaining useful life prediction of bearings by a new reinforced memory gru network. *Advanced Engineering Informatics*, 53:101682, 2022.
- [16] J. Shi, T. Yu, K. Goebel, and D. Wu. Remaining useful life prediction of bearings using ensemble learning: The impact of diversity in base learners and features. *Journal of Computing and Information Science in Engineering*, 21(2):021004, 2021.
- [17] T. Wang, Z. Liu, and N. Mrad. A probabilistic framework for remaining useful life prediction of bearings. *IEEE Transactions on Instrumentation and Measurement*, 70:1–12, 2020.

واژه‌نامه

ت

experimental	تجربی	heuristic	ابتکاری
density	تراکم	high dimensions	ابعاد بالا
approximation	تقریب	bias	اریب
partition	تقسیم‌بندی	threshold	آستانه
mesh	توری	pigeonhole principle	اصل لانه‌ی کبوتری
distributed	توزیع شده	NP-Hard	ان‌پی-سخت
		transition	انتقال

ج

separable	جداپذیر	online	برخط
black box	جعبه سیاه	linear programming	برنامه‌ریزی خطی
data stream	جویبار داده	optimum	بهینه
		maximum	بیشینه

ح

extreme	حدی	outlier	پرت
greedy	حریصانه	query	پرسمان
		cover	پوشش
cluster	خوشه	complexity	پیچیدگی
linear	خطی		

الف

ب

پ

ف

distance	فاصله
space	فضا

ق

deterministic	قطعی
---------------------	------

د

data	داده
data mining.....	داده‌کاوی
outlier data	داده‌ی پرت
doubling	دوبابرسازی
binary	دودویی

ک

efficient	کارا
candidate	کاندیدا
minimum	کمینه

ر

vertex	رأس
formal	رسمی

م

set	مجموعه
coreset	مجموعه هسته
planar	مسطح
parallelization	موازی‌سازی
buffer	میانگیر

sublinear	زیرخطی
-----------------	--------

س

amortized	سرشکن
hierarchichal	سلسه‌مراتبی

ش

pseudocode	شبه کد
object	شیء
center point	نقطه‌ی مرکزی
half space	نیم‌فضا
satisfiability	صدق‌پذیری

ن

inversion	نابه‌جایی
invariant	ناوردا
center point	نقطه‌ی مرکزی

ص

satisfiability	صدق‌پذیری
----------------------	-----------

ه

price of anarchy (POA)	هزینه‌ی آشوب
------------------------------	--------------

dominate	غلبه
----------------	------

غ**ی**

edge	یال
------------	-----

آپیوست

مطالب تکمیلی

پیوست‌های خود را در صورت وجود می‌توانید در این قسمت قرار دهید.

Abstract

In industrial environments and factories, one of the most important concerns is the maintenance and repair of tools and industrial equipment. Each piece of equipment plays a crucial role in the production line of any company, and the smallest damage or malfunction can disrupt the entire production process. Therefore, it is essential to continuously monitor the current health status of the equipment and predict the time of potential failures and the remaining useful life.

The prediction of Remaining Useful Life (RUL) is a critical task in the field of Prognostics and Health Management (PHM) for industrial tools and equipment. Accurate RUL prediction is vital because it enables timely maintenance and repair, reduces downtime, and allows for the optimization of operational efficiency by loading the equipment according to its remaining useful life.

Keywords: Remaining Useful Life, RUL, Transformer, FPGA



Amirkabir University of Technology

(Tehran Polytechnic)

Department of Computer Engineering

M.Sc. Seminar Report

FPGA-Based Hardware Acceleration of Remaining Useful Life Prediction of Rotating Machinery Using Transformer Neural Network

By:

Reza Adinepour

Supervisor:

Prof. Morteza Saheb Zamani

August 2024